

Régression Logistique

Master MLDS - 2017/2018

Université Paris Descartes

Lazhar.labiod@parisdescartes.fr

Introduction

- ▶ Le modèle de régression linéaire que nous avons vu jusqu'à présent est un modèle qui s'applique à prédire une variable continue en fonction d'une variable continue
- ▶ Il arrive souvent que l'on veuille prédire une variable binaire à partir d'une (ou plusieurs) variable(s) continue(s) (ou nominales), c'est ce que permet de faire la régression logistique $x \in \mathbb{R}, y \in \{0, 1\}$
- ▶ Dans le cas où la variable à prédire Y est une variable nominale (catégorique) on parle de classification. Lorsque la variable Y est continue, on parle de régression.

Introduction

- ▶ Problème : prédire une variable à deux issues $Y = \{0, 1\}$ dont l'une est le succès ($Y = 1$) et l'autre un échec ($Y = 0$).
- ▶ En réutilisant une technique de régression, on peut chercher la probabilité d'obtenir le succès $P(Y = 1)$, il est alors possible de déduire la probabilité de l'échec : $P(Y = 0) = 1 - P(Y = 1)$
- ▶ On peut se munir d'une règle de décision qui pour un seuil θ décide : $Y = 1$ si $P(Y = 1) > \theta$ et 0 sinon

$$Y = \begin{cases} 1 & \text{si } P(Y = 1) > \theta \\ 0 & \text{sinon} \end{cases}$$


- ▶ avec $\theta = 0.5$ en première approximation

Introduction ...

- ▶ On pourrait envisager réutiliser la régression linéaire pour prédire des valeurs 0 et 1 avec une règle de décision du type :


$$Y = \begin{cases} 1 & \text{si } f(x) = \alpha + \beta(x) > 0.5 \\ 0 & \text{sinon} \end{cases}$$

- ▶ Le problème est que la régression linéaire produit des valeurs qui sont inévitablement en dehors de l'intervalle $[0, 1] \in \mathbb{R}$ et qui ne s'interprètent pas comme des probabilités
- ▶ La régression linéaire va en effet prédire des valeurs continues sur \mathbb{R} , or on veut uniquement prédire dans l'intervalle $[0, 1] \in \mathbb{R}$



Fonction logistique

- ▶ Les nuages de points dont la variable Y est une variable a valeurs dans $[0, 1]$ ne se résument plus par une droite mais par une fonction qui décrit une courbe en S, la fonction logistique (ou sigmoïde)



$$\Pr(Y = 1 \mid X = x) = \frac{\exp(\beta_0 + \beta x)}{1 + \exp(\beta_0 + \beta x)},$$

$$\Pr(Y = 0 \mid X = x) = \frac{1}{1 + \exp(\beta_0 + \beta x)}$$

Illustration

- ▶ `> x <- seq(-10,10,0.1)`
- ▶ `> beta0 <- 1`
- ▶ `> beta <- 1`
- ▶ `> y <- exp(beta0 +beta * x)/(1+ exp(beta0 +beta * x))`
- ▶ `> plot(x,y)`
- ▶ *# Essayer avec les combinaisons:*
- ▶ *# beta0 {-2,0,2}*
- ▶ *# beta {-2,-1,1,2}*

Calcul d'une régression logistique

- ▶ On a un nuage de points qui se résume par la fonction :

$$\hat{y} = \Pr(Y = 1 | X = x) = \frac{\exp(\beta_0 + \beta x)}{1 + \exp(\beta_0 + \beta x)},$$

- ▶ Or cette fonction comporte la version linéaire $\beta_0 + \beta x$
- ▶ On sait comment calculer une régression pour une fonction linéaire
- ▶ Idée : projeter la fonction logistique dans un espace linéaire et faire le calcul

Fonction logit

- ▶ La fonction logit permet de projeter le problème dans un espace linéaire

- ▶ Preuve

$$\text{logit}(x) = \ln\left(\frac{x}{1-x}\right)$$

$$\begin{aligned}\text{logit}\left(\frac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}\right) &= \ln\left(\frac{\frac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}}{1 - \frac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}}\right) \\ &= \ln\left(\frac{\frac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}}{\frac{1+e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}} - \frac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}}\right) \\ &= \ln\left(\frac{\frac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}}{\frac{1}{1+e^{\alpha+\beta x}}}\right) \\ &= \ln\left(e^{\alpha+\beta x}\right) \\ &= \alpha + \beta x\end{aligned}$$

La régression logistique binaire (K=2)

► Les données

Y = variable à expliquer binaire

X^1, \dots, X^p = variables explicatives numériques
ou binaires (indicatrices de modalités)

- Régression logistique simple ($p = 1$)
- Régression logistique multiple ($p > 1$)

La régression logistique simple

- ▶ Variable dépendante : $Y = 0 / 1$
- ▶ Variable indépendante : X
- ▶ Objectif : Modéliser

$$\pi(x) = \Pr(Y = 1/X = x)$$


- Le modèle linéaire $\pi(x) = \beta_0 + \beta_1 x$ convient mal lorsque X est continue.
- Le modèle logistique est plus naturel.

Exemple : Age and Coronary Heart Disease Status (CHD)

Les données

ID	AGRP	AGE	CHD
1	1	20	0
2	1	23	0
3	1	24	0
4	1	25	0
5	1	25	1
⋮	⋮	⋮	⋮
97	8	64	0
98	8	64	1
99	8	65	1
100	8	69	1

Plot of CHD by Age



Le modèle logistique


$$\pi(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

ou

$$\text{Log}\left(\frac{\pi(x)}{1 - \pi(x)}\right) = \beta_0 + \beta_1 x$$

Fonction de lien : Logit

Probabilité d'une maladie cardiaque
en fonction de l'age



Estimation des paramètres du modèle logistique

Les données

X	Y
x₁	y₁
⋮	⋮
x_i	y_i
⋮	⋮
x_n	y_n

$y_i = 1$ si caractère présent,
0 sinon

Le modèle

$$\begin{aligned}\pi(x_i) &= P(Y = 1 / X = x_i) \\ &= \frac{e^{\beta + \beta x_i}}{1 + e^{\beta + \beta x_i}}\end{aligned}$$

Vraisemblance des données

Probabilité d'observer les données

$$[(x_1, y_1), \dots, (x_i, y_i), \dots, (x_n, y_n)]$$

$$= \prod_{i=1}^n \text{Prob}(Y = y_i \mid X = x_i)$$

$$= \prod_{i=1}^n \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}$$

$$= \prod_{i=1}^n \left(\frac{e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}} \right)^{y_i} \left(\frac{1}{1 + e^{\beta_0 + \beta_1 x_i}} \right)^{1-y_i}$$

$$= l(\beta_0, \beta_1)$$

Log-Vraisemblance

$$L(\beta_0, \beta_1) = \text{Log}(l(\beta_0, \beta_1)) = \text{Log}\left[\prod_{i=1}^n \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}\right]$$

$$= \sum_{i=1}^n y_i \text{Log}\left(\frac{\pi(x_i)}{1 - \pi(x_i)}\right) + \text{Log}(1 - \pi(x_i))$$

$$= \sum_{i=1}^n y_i (\beta_0 + \beta_1 x_i) - \text{Log}(1 + \exp(\beta_0 + \beta_1 x_i))$$

Estimation du maximum de vraisemblance

- ▶ On cherche $\hat{\beta}_0$ et $\hat{\beta}_1$ maximisant la Log-vraisemblance $L(\hat{\beta}_0, \hat{\beta}_1)$.

- ▶ La matrice

$$V(\hat{\beta}) = \begin{bmatrix} V(\hat{\beta}_0) & \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) \\ \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) & V(\hat{\beta}_1) \end{bmatrix}$$

est estimée par la matrice

$$\left[-\frac{\partial^2 L(\beta)}{\partial \beta \partial \beta'} \right]_{\beta = \hat{\beta}}^{-1}$$

La régression logistique multi-classe ($K > 2$)

La méthode modélise directement les probabilités a posteriori comme des variables à expliquer d'une régression

$$\Pr(Y = k \mid X = x) = \frac{\exp(\beta_{k0} + \beta_k^T x)}{1 + \sum_{l=1}^{K-1} \exp(\beta_{l0} + \beta_l^T x)}, \quad k = 1, \dots, K-1$$

$$\Pr(Y = K \mid X = x) = \frac{1}{1 + \sum_{l=1}^{K-1} \exp(\beta_{l0} + \beta_l^T x)}$$

x une observation (un vecteur p -dimensionnel)

β_k un vecteur p -dimensionnel pour chaque k

Nombre total des paramètres $(K-1)(p+1)$

Noter que les frontières des classes sont linéaires

Validation du modèle logistique

- ▶ Comme pour la régression linéaire, il est important de :
- ▶ Vérifier la validité du modèle
- ▶ Prouver la qualité de l'ajustement.

Conclusion

- ▶ La régression logistique est une méthode de classification très utilisée, notamment pour $K = 2$.
- ▶ LDA est utile quand n est petit ou les classes sont bien séparées, et l'hypothèse sur la distribution gaussienne des variables est raisonnable. Egaleme^{nt} elle marche bien quand $K > 2$
- ▶ Le classifieur bayésien naif est utile quand p est très grand.

Régression logistique versus LDA

- Pour un problème à deux classes on peut montrer que

$$\text{Log}\left(\frac{\pi(x)}{1-\pi(x)}\right) = \beta_0 + \beta_1 x^1 + \beta_2 x^2 + \dots + \beta_p x^p$$

- Elle a la même forme que la régression logistique
- La différence entre les deux méthodes réside dans l'estimation des paramètres
 - La régression logistique utilise la vraisemblance conditionnelle basée sur $\Pr(Y/X)$ (une méthode discriminative).
 - LDA utilise la vraisemblance basée sur $\Pr(X, Y)$ (une méthode générative).
 - Malgré ces différences, en pratique, elles donnent des résultats similaires
- La régression logistique permet également d'ajuster des frontières quadratiques comme la méthode LDA, en injectant explicitement des termes quadratiques dans le modèle